

第四章 回归分析

4.1 一元线性回归分析

回归分析

回归分析是用来寻找若干变量之间统计联系（关系）的一种方法。它是一种统计模型，分为线性回归和非线性回归，线性回归在气象中最为常用（解释性好，物理机理较为清晰）。利用回归分析得到的统计关系对某一变量作出未来时刻的估计，称为预报值(量)。前期（也可以是同期因子）已发生的多个与之有关的气象要素称为预报因子。

案例分析

为了预报某地某月平均气温或降水量情况（预报量），选择预报前期已发生的多个有关的气象要素（预报因子），利用回归分析方法分析多个预报因子和预报变量之间的相互关系，建立统计关系的方程式，最后利用其对未来时刻的气温或降水量作出预报估计。

一元回归

一元回归分析处理的是两个变量之间的关系，即一个预报量和一个预报因子之间的关系。

4.1.1 回归模型

基本原理

对抽取容量为 n 的预报量 y 与预报因子 x 的一组样本（必须保证样本个数一致），若认为 y 与 x 是一元线性统计关系，则线性回归方程为： $y_i = b_0 + bx_i + \varepsilon_i$, $i = 1, 2, \dots, n$ (ε_i 为残差项，我们希望它越小越好)，那么预报量的估计量 \hat{y} 与 x 有如下关系：

$$\hat{y}_i = b_0 + bx_i \quad i = 1, 2, \dots, n$$

或写为一般的回归方程： $\hat{y} = b_0 + bx$ ，其中 b_0 为截距， b 为斜率。

最小二乘法

对所有的 x_i ，若 \hat{y}_i 与 y_i 的偏差最小，就认为所确定的直线能最好地代表所有实测点的散布规律。

为了消除偏差符号的影响，可以用偏差的平方来反映偏差的绝对值偏离情况。

全部观测值与回归直线的离差平方和记为：

$$Q(b_0, b) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

它刻画了全部观测值与回归直线的偏离程度。显然 Q 值越小越好， Q 是待定系数 b_0 和 b 的函数。

标准方程组

根据极值原理，要求： $\frac{\partial Q}{\partial b_0} = 0, \frac{\partial Q}{\partial b} = 0$ 。整理得到求回归系数 b_0 、 b 的方程组：

$$\begin{cases} nb_0 + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \\ b_0 \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \end{cases}$$

称为求回归系数的标准方程组。

具体求解

$$\textcircled{1} \quad \frac{\partial Q}{\partial b_0} = \frac{\partial}{\partial b_0} \left(\sum_{i=1}^n (y_i - b_0 - bx_i)^2 \right) = \sum_{i=1}^n -2(y_i - b_0 - bx_i) = 0 \Rightarrow \sum_{i=1}^n (-y_i - b_0 - bx_i) = 0 \Rightarrow$$

$$nb_0 + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \quad \text{其中} \quad \frac{\partial (y_i - b_0 - bx_i)^2}{\partial b_0} = 2(y_i - b_0 - bx_i) \cdot (-1)。$$

$$\textcircled{2} \quad \frac{\partial Q}{\partial b} = \frac{\partial}{\partial b} \left(\sum_{i=1}^n (y_i - b_0 - bx_i)^2 \right) = -2 \sum_{i=1}^n x_i (y_i - b_0 - bx_i) = 0 \Rightarrow b_0 \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

回归系数	$b_0 = \bar{y} - b\bar{x}$	$b = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{s_{xy}}{s_x^2}$
距平形式	将 $b_0 = \bar{y} - b\bar{x}$ 代入回归方程 $\hat{y}_i = b_0 + bx_i$, 得到 $\hat{y}_i - \bar{y} = b(x_i - \bar{x})$ 或 $\hat{y}_{di} = bx_{di}$	
标准化形式	发现有关系: $b = \frac{s_{xy}}{s_x^2} = \frac{s_{xy}}{s_x s_y} \cdot \frac{s_y}{s_x} = r_{xy} \cdot \frac{s_y}{s_x}$, 由此 $\hat{y}_{zi} = r_{xy} x_{zi}$ (这里的 x, y 都是标准化后的变量)	
相关系数	回归系数 b 与相关系数之间的关系: $b = \frac{s_{xy}}{s_x^2} = r_{xy} \cdot \frac{s_y}{s_x}$	相关系数 r 与回归系数 b 同号
	当 $b < 0$, 回归直线斜率为负, 预报量 y 随预报因子 x 增加而减少, 反映预报量与因子是负相关。	
	当 $b > 0$, 回归直线斜率为正, 预报量 y 随预报因子 x 增加而增加, 反映预报量与因子是正相关。	
4.1.2 回归问题的方差分析		
意义	评价回归方程的优劣	
预报量方差	预报量方差可以表示成回归估计值的方差(回归方差)和误差(残差)方差之和:	
	$\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	
	即 $s_y^2 = s_{\hat{y}}^2 + s_e^2$ 。	
评估分析	方差分析表明, 预报量 y 的变化可以看成由前期因子 x 的变化所引起的, 同时加上随机因素 e 的影响, 这种前期因子 x 的变化影响可以用回归方差的大小来衡量。如果回归方差大/残差方差小, 表明用线性关系解释 y 与 x 的关系比较符合实际情况, 回归模型比较好。	
离差平方和	$\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 两边同时乘以 n 变成各变量离差平方和的关系。	
	总离差平方和: $s_{yy}^2 = U + Q = \sum_{i=1}^n (y_i - \bar{y})^2$	反映因变量 y 的 n 个观测值与其均值的总离差
	回归平方和: $U = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	反映回归值的分散程度
	残差平方和: $Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2$	反映观测值偏离回归直线的程度
4.1.3 相关系数与线性回归		
判决系数	因为回归方差不可能大于预报量的方差, 可以用它们的比值来衡量方程的拟合效果。即:	
	$\frac{s_{\hat{y}}^2}{s_y^2} = \frac{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} = \frac{U}{s_{yy}^2} = r^2_{xy}$	
	上式表明预报因子 x 对预报量 y 的方差的线性关系程度, 这一比值又称为回归方程判决系数/解释方差。	
	判决系数是衡量两个变量线性关系密切程度的量, 等于两变量相关系数的平方。	
	如果是多元线性回归, 合理猜想, 是复相关系数的平方。	
物理含义	① 回归平方和占总离差平方和的比例 ③ 取值范围在 $[0, 1]$ ⑤ $r^2 \rightarrow 1$ 说明回归方程拟合的越好, $r^2 \rightarrow 0$ 说明回归方程拟合的越差	② 反映回归直线的拟合程度 ④ 判决系数等于相关系数的平方
4.1.4 回归方程的显著性检验		
中心思想	显著性检验的主要思想是检验预报因子与预报量是否有线性关系。	
统计量	可以证明在原假设总体回归系数为 0 的条件下, 统计量:	
	$F = \frac{U/1}{Q/(n-2)}$	
	遵从分子自由度为 1, 分母自由度为 $(n-2)$ 的 F 分布。	
显著性检验	查 F 的分布表, 在 $\alpha = 0.05$ 下, 若 $F > F_{\alpha}$ 则认为回归方程是显著的。反之, 则不显著。	
相关系数	统计量 F 也可以写为: $F = \frac{U/1}{Q/(n-2)} = \frac{s_{\hat{y}}^2/1}{s_e^2/(n-2)} = \frac{r^2}{(1-r^2)/(n-2)}$, 与 $t = \frac{r}{\sqrt{1-r^2}} \sqrt{n-2}$ 比较, 发现二者等价。	
注意	F 的相关系数表达式开方就是相关系数 t 检验的表达式, 故一元回归方程的检验与相关系数的检验一致。	

4.1.5 回归系数的显著性检验

说明 气象中使用最多的是回归方程的距平形式，所以对回归方程的显著性检验可以只对因子的回归系数进行检验。

统计量 在原假设 $H_0: \text{回归系数 } \beta = 0$ 的条件下

① 统计量 $t = \frac{b - \beta}{\sqrt{\frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} = \frac{b/\sqrt{c}}{\sqrt{Q/(n-2)}}$ 遵从自由度为 $n - 2$ 的 t 分布。

$$\text{其中: } \hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{Q}{n-2} \quad c = [\sum_{i=1}^n (x_i - \bar{x})^2]^{-1}$$

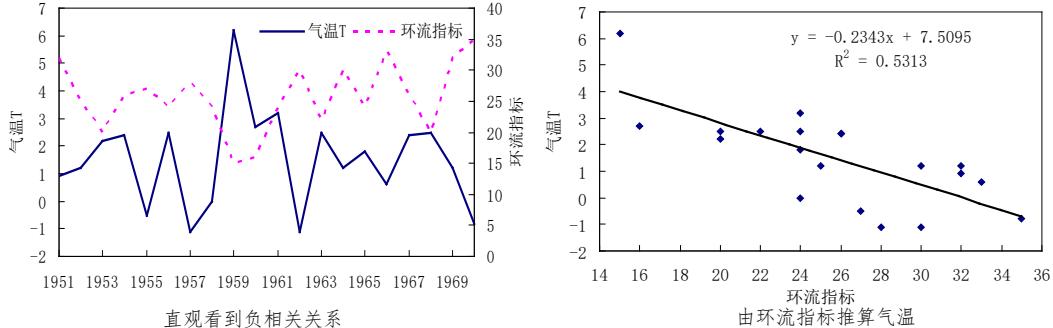
② 或者根据 F 分布与 t 分布的关系，统计量 $F = \frac{U/1}{Q/(n-2)} = \frac{b^2/c}{Q/(n-2)}$ 遵从分子自由度为 1，分母自由度为 $n - 2$ 的 F 分布。其中 $U = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (b_0 - bx_i - b_0 - b\bar{x})^2 = b^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{b^2}{c}$

4.1.6 预报值的置信区间

置信区间 因为 $e_i = y_i - E(y_i)$ 可以看成遵从 $N(0, \sigma^2)$ 的正态分布，所以其 95% 的置信区间为 $E(y_i) \pm 1.96\sigma$ 。
 $E(y_i)$ 可用 $b_0 + bx_i = \hat{y}_i$ 估计， σ 可用无偏估计量 $\hat{\sigma} = \sqrt{\frac{Q}{n-2}}$ 估计， $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
预报值的 95% 置信区间可近似估计为 $[\hat{y}_i - 1.96\hat{\sigma}, \hat{y}_i + 1.96\hat{\sigma}]$ 。
每一个点的置信区间都不一样，置信区间上下界是一个曲线。

4.1.7 一元线性回归分析预测步骤

分析数据



第一步 计算回归系数，确定方程。对上述资料，容易算得 $n = 20$, $\sum_{i=1}^{\infty} x_i = 513$, $\sum_{i=1}^{\infty} y_i = 30.0$,

$$\sum_{i=1}^1 x_i^2 = 13721, \sum_{i=1}^2 x_i y_i = 637 \quad \text{根据 } b_0 = \bar{y} - b\bar{x}, b = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{S_{xy}}{S_x^2}$$

$$b_0 = 7.5, b = -0.23 \quad \text{最终得到回归方程: } \hat{y} = 7.5 - 0.23x$$

第二步 回归方程显著性检验。

$$\text{再次计算得到: } \sum_{i=1}^1 y_i^2 = 103.12 \quad \text{于是 } r_{xy} = \sqrt{\frac{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} = \sqrt{\frac{13721 - \frac{1}{20} \times (513)^2}{103.12 - \frac{1}{20} \times (30.0)^2}} \times (-0.23) = -0.727$$

$$\text{最终得到: } F = \frac{(-0.727)^2}{[1 - (-0.727)^2]/(20-2)} = 20.18 \quad \text{查询} F \text{ 分布表, 在} \alpha = 0.05, \text{ 分子自由度为 1, 分母自由度为 18 时, } F_{\alpha} = 4.41 \quad \text{由于 } F > F_{\alpha} \quad \text{认为回归方程是显著的。 (考试可以灵活应用} t \text{ 检验)}$$

第三步 计算预报值的置信区间，作出预测。

$$\text{将} x = 24 \text{ 代入回归方程, 计算出预报值为 } y_{24} = 1.98^{\circ}\text{C}, \text{ 又有 } Q = s_{yy} - U = s_{yy} - s_{yy}r^2 = s_{yy}(1 - r^2)$$

$$\text{算出: } \hat{\sigma} = \sqrt{\frac{1}{20-2} \times 58.12(1 - 0.727^2)} = 1.11, \quad \text{用 } E(y_i) \pm 1.96\sigma \text{ 得到置信区间。}$$

所以 1971 年北京 3 月下旬气温的 95% 置信区间为 $-0.2 \sim 4^{\circ}\text{C}$ 。

4.2 多元线性回归分析

4.2.1 多元回归模型

模型定义 描述因变量 y 如何依赖于多个自变量 x_1, x_2, \dots, x_p 和误差项 ε 的方程，称为**多元回归模型**。

预报因子的选择在实际研究中十分困难，而且多个物理因子之间的协同是非线性的。

涉及 p 个自变量的**多元线性回归模型**可表示为：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

其中 $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ 是参数， ε 是被称为误差项的随机变量，包含在 y 里面但不能被 p 个自变量的线性关系所解释的变异性。

结构表达式 假定预报量 y 与 p 个预报因子关系是线性（先画图观察），为研究它们之间的联系作 **n 次抽样**，则可得到如下结构表达式： $y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_p x_{pt} + e_t, t = 1, 2, \dots, n$ 展开：

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{21} + \dots + \beta_p x_{p1} + e_1 \\ y_2 = \beta_0 + \beta_1 x_{12} + \beta_2 x_{22} + \dots + \beta_p x_{p2} + e_2 \\ \dots \\ y_n = \beta_0 + \beta_1 x_{1n} + \beta_2 x_{2n} + \dots + \beta_p x_{pn} + e_n \end{cases} \quad (1)$$

也可以写成**矩阵形式**： $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ (2)

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \quad \mathbf{e} = \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix} \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & \dots & x_{p1} \\ 1 & x_{12} & \dots & x_{p2} \\ \dots & \dots & \dots & \dots \\ 1 & x_{1n} & \dots & x_{pn} \end{bmatrix}$$

回归方程 我们得到的是一组实测 p 个变量的样本，利用这组样本 (n 次抽样) 对上述回归模型进行估计，得到的**估计方程**（没有 ε ）为多元线性回归方程，记为：

$$\hat{\mathbf{y}} = \mathbf{b}_0 + \mathbf{b}_1 \mathbf{x}_1 + \mathbf{b}_2 \mathbf{x}_2 + \dots + \mathbf{b}_p \mathbf{x}_p$$

其中 \mathbf{b}_i 是 β_i 的估计值，下面讨论如何确定它们。

4.2.2 回归系数最小二乘估计

回归方程 和一元线性回归类似，在样本容量为 n 的 y 预报量和因子变量 x 的实测值中，满足线性回归方程：

$$\hat{y}_t = b_0 + b_1 x_{1t} + b_2 x_{2t} + \dots + b_p x_{pt} \quad t = 1, 2, \dots, n$$

计算方法 要求回归系数，应使全部的**预报量观测值与回归估计值的残差平方和**达到最小。

$$Q = \sum_{t=1}^n (y_t - \hat{y}_t)^2 = \sum_{t=1}^n (y_t - b_0 - b_1 x_{1t} - b_2 x_{2t} - \dots - b_p x_{pt})^2$$

由**极值定理**： $\begin{cases} \frac{\partial Q}{\partial b_0} = 0 \\ \frac{\partial Q}{\partial b_1} = 0 \\ \vdots \\ \frac{\partial Q}{\partial b_p} = 0 \end{cases} \quad \begin{cases} nb_0 + b_1 \sum_t x_{1t} + b_2 \sum_t x_{2t} + \dots + b_p \sum_t x_{pt} = \sum_t y_t \\ b_0 \sum_t x_{1t} + b_1 \sum_t x_{1t}^2 + b_2 \sum_t x_{2t} x_{1t} + \dots + b_p \sum_t x_{pt} x_{1t} = \sum_t y_t x_{1t} \\ b_0 \sum_t x_{2t} + b_1 \sum_t x_{1t} x_{2t} + b_2 \sum_t x_{2t}^2 + \dots + b_p \sum_t x_{pt} x_{2t} = \sum_t y_t x_{2t} \\ \dots \\ b_0 \sum_t x_{pt} + b_1 \sum_t x_{1t} x_{pt} + b_2 \sum_t x_{2t} x_{pt} + \dots + b_p \sum_t x_{pt}^2 = \sum_t y_t x_{pt} \end{cases}$

4.2.3 线性回归模型的其他形式

4.2.3.1 距平形式的多元回归方程

距平形式 我们先看第一行的方程： $\frac{\partial Q}{\partial b_0} = 0 \Rightarrow b_0 = \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2 - \dots - b_p \bar{x}_p$ 得到 b_0 ，将 b_0 代入待求方程：

$$\hat{y}_t = b_0 + b_1 x_{1t} + b_2 x_{2t} + \dots + b_p x_{pt} \Rightarrow \hat{y}_t - \bar{y} = b_1(x_{1t} - \bar{x}_1) + b_2(x_{2t} - \bar{x}_2) + \dots + b_p(x_{pt} - \bar{x}_p)$$

$\Rightarrow \hat{\mathbf{y}}_d = \mathbf{b}_1 \mathbf{x}_{d1} + \mathbf{b}_2 \mathbf{x}_{d2} + \dots + \mathbf{b}_p \mathbf{x}_{dp}$ 即为**距平形式的回归方程** (d 表示距平的下标)

根据距平形式的方程，由于各个回归系数相同，且能够计算出 b_0 ，故可以得到原始方程。

求解 残差平方和为 $Q = \sum_{t=1}^n (y_{dt} - \hat{y}_{dt})^2 = \sum_{t=1}^n (y_{dt} - b_1 x_{d1t} - b_2 x_{d2t} - \dots - b_p x_{dpt})^2$

从距平变量的观测值求回归系数，同样用最小二乘法导出求回归系数的标准方程组：

$$\begin{cases} b_1 \sum_t x_{d1t}^2 + b_2 \sum_t x_{d2t}x_{d1t} + \dots + b_p \sum_t x_{dpt}x_{d1t} = \sum_t y_{dt}x_{d1t} \\ b_1 \sum_t x_{d1t}x_{d2t} + b_2 \sum_t x_{d2t}^2 + \dots + b_p \sum_t x_{dpt}x_{d2t} = \sum_t y_{dt}x_{d2t} \\ \dots \\ b_1 \sum_t x_{d1t}x_{dpt} + b_2 \sum_t x_{d2t}x_{dpt} + \dots + b_p \sum_t x_{dpt}^2 = \sum_t y_{dt}x_{dpt} \end{cases} \quad \text{发现中间各项是协方差形式}$$

为了得到协方差矩阵形式，上式两边乘上 $1/n$ ，变成各变量的协方差形式，相应的方程组写为：

$$\begin{cases} b_1 s_{11} + b_2 s_{12} + \dots + b_p s_{1p} = s_{1y} \\ b_1 s_{21} + b_2 s_{22} + \dots + b_p s_{2p} = s_{2y} \\ \dots \\ b_1 s_{p1} + b_2 s_{p2} + \dots + b_p s_{pp} = s_{py} \end{cases} \quad s_{kl} = \frac{1}{n} \sum_{i=1}^n x_{dik}x_{dil} \quad s_{ky} = \frac{1}{n} \sum_{i=1}^n x_{dik}y_{di} \quad k, l = 1, 2, \dots, p$$

4.2.3.2 标准化形式的多元回归方程

标准化形式 对距平变量多元线性回归方程两边除以预报量 y 的标准差 s_y ，得到：

距平形式的回归方程为 $\hat{y}_d = b_1 x_{d1} + b_2 x_{d2} + \dots + b_p x_{dp}$ 将其除以 s_y 得到：

$$\frac{\hat{y}_d}{s_y} = \frac{b_1 x_{d1}}{s_y} + \frac{b_2 x_{d2}}{s_y} + \dots + \frac{b_p x_{dp}}{s_y} \Rightarrow \frac{\hat{y}_d}{s_y} = b_1 \frac{s_1}{s_y} \frac{x_{d1}}{s_1} + b_2 \frac{s_2}{s_y} \frac{x_{d2}}{s_2} + \dots + b_p \frac{s_p}{s_y} \frac{x_{dp}}{s_p} \quad \text{系数改变}$$

令标准化回归系数为： $b_{zk} = b_k \frac{s_k}{s_y} \quad (k = 1, 2, \dots, p)$

$\Rightarrow \hat{y}_z = b_{z1} x_{z1} + \dots + b_{zp} x_{zp}$ 标准化形式的回归方程 (z 表示标准化的下标)

根据标准化形式的方程，由于能够计算出 s_k, s_y ，故可以得到距平方程，因此三个方程互通。

求解

残差平方和为 $Q = \sum_{t=1}^n (y_{zt} - \hat{y}_{zt})^2 = \sum_{t=1}^n (y_{zt} - b_1 x_{z1t} - b_2 x_{z2t} - \dots - b_p x_{zpt})^2$

从标准化变量的观测值求回归系数，同样用最小二乘法导出求回归系数的标准方程组：

$$\begin{cases} b_{z1} \sum_t x_{z1t}^2 + b_{z2} \sum_t x_{z2t}x_{z1t} + \dots + b_{zp} \sum_t x_{zpt}x_{z1t} = \sum_t y_{zt}x_{z1t} \\ b_{z1} \sum_t x_{z1t}x_{z2t} + b_{z2} \sum_t x_{z2t}^2 + \dots + b_{zp} \sum_t x_{zpt}x_{z2t} = \sum_t y_{zt}x_{z2t} \\ \dots \\ b_{z1} \sum_t x_{z1t}x_{zpt} + b_{z2} \sum_t x_{z2t}x_{zpt} + \dots + b_{zp} \sum_t x_{zpt}^2 = \sum_t y_{zt}x_{zpt} \end{cases} \quad \text{发现中间各项是相关系数形式}$$

上式两边乘上 $1/n$ ，变成各变量的相关系数形式，相应的方程组写为：

$$\begin{cases} r_{11}b_{z1} + r_{12}b_{z2} + \dots + r_{1p}b_{zp} = r_{1y} \\ r_{21}b_{z1} + r_{22}b_{z2} + \dots + r_{2p}b_{zp} = r_{2y} \\ \dots \\ r_{p1}b_{z1} + r_{p2}b_{z2} + \dots + r_{pp}b_{zp} = r_{py} \end{cases}$$

4.2.4 回归问题的方差分析

回归方差 回归方差可表示为： $s_{\hat{y}}^2 = \frac{1}{n} U = \sum_{k=1}^p b_k s_{ky}$ 回归系数与 ky 的协方差

对于**标准化变量**而言，回归方差为： $s_{\hat{y}_z}^2 = \sum_{k=1}^p b_{zk} r_{ky}$ 关系好不代表关系显著

如果回归方差大，表明用线性关系解释 y 与 x 的关系比较符合实际情况，回归模型比较好。

推导

回归平方和为： $U = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ 将其展开：

$$\sum_{i=1}^n (\hat{y}_i - \bar{y})[(y_i - \bar{y}) - (\hat{y}_i - \bar{y})] = \sum_{i=1}^n (\hat{y}_i - \bar{y})(y_i - \bar{y}) - \sum_{i=1}^n (\hat{y}_i - \bar{y})(\hat{y}_i - \bar{y})$$

发现 $\sum_{i=1}^n (\hat{y}_i - \bar{y})(\hat{y}_i - \bar{y}) = 0$ ，因此 $U = n \sum_{k=1}^p b_k s_{ky}$ 。

4.2.5 复相关系数

复相关系数 衡量一个预报量与多个变量之间线性关系程度的量，即衡量预报量 y 与估计量 \hat{y} 之间线性相关程度的量：

$$R = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{y})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}}} = \sqrt{\frac{U}{S_{yy}}}, \quad R^2 = 1 - \frac{Q}{S_{yy}}$$

称为多元回归方程的可解释系数。

4.2.6 回归方程的显著性检验

总体检验 回归方程的显著性检验和一元回归类似：假设总体回归系数为 0 时 $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$

$$F = \frac{U/p}{Q/(n-p-1)} = \frac{\frac{U}{S_{yy}}/p}{\frac{Q}{S_{yy}}/(n-p-1)} = \frac{\frac{R^2}{p}}{\frac{1-R^2}{n-p-1}}$$

遵从分子自由度为 p , 分母自由度为 $n - p - 1$ 的 F 分布。

显著性检验 在显著性水平下 $\alpha = 0.05$, 若 $F > F_\alpha$ 则认为回归方程是显著的。反之，则不显著。

注意 方程显著，不代表每个回归系数都是显著的。

4.2.7 预报值的置信区间

置信区间 因为 $e = y_i - E(y_i) \sim N(0, \sigma^2)$ 的正态分布，所以其 95% 的置信区间为 $E(y_i) \pm 1.96\sigma$

$E(y_i)$ 可用 \hat{y}_i 估计， σ 可用无偏估计量 $\hat{\sigma} = \sqrt{\frac{Q}{n-p-1}}$ 估计， $\hat{\sigma}^2 = \frac{1}{n-p-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

预报值的 95% 置信区间可近似估计为 $[\hat{y}_i - 1.96\hat{\sigma}, \hat{y}_i + 1.96\hat{\sigma}]$

4.2.8 气象应用与实例

基本步骤 ① 确定预报量并选择恰当的因子。

② 根据数据计算回归系数标准方程组所包含的有关统计量（因子的交叉积、协方差阵或相关阵，以及因子与预报量交叉积、协方差或相关系数）。

③ 解线性方程组求出回归系数。

④ 建立回归方程并进行统计显著性检验。

⑤ 利用已出现的因子值代入回归方程作出预报量的估计，求出预报值的置信区间。

实例分析

设对某一预报量 y , 选择 4 个因子作预报, 样本容量 $n = 13$ 。

i	1	2	3	4	5	6	7	8	9	10	11	12	13
x_1	7	1	11	11	7	11	3	1	2	21	1	11	10
x_2	26	29	56	31	52	55	71	31	54	47	40	66	68
x_3	6	15	8	8	6	9	17	22	18	4	23	9	8
x_4	60	52	20	47	33	22	6	44	22	26	34	12	12
y	78.5	74.3	104.3	87.6	95.9	109.2	102.7	72.5	93.1	115.9	83.8	113.3	109.4

为了说明问题，我们选取 x_1, x_2, x_4 作为因子，使用标准化变量的回归方程，求标准回归系数的方程组为：

$$\begin{cases} b_1 + 0.2286b_2 - 0.2455b_4 = 0.7307 \\ 0.2286b_1 + b_2 - 0.9730b_4 = 0.8163 \\ -0.2455b_1 - 0.9730b_2 + b_4 = -0.8213 \end{cases}$$

上式系数都是相关系数。得出回归方程为： $\hat{y} = 0.5679x_1 + 0.4323x_2 - 0.2613x_4$ 。

计算回归方差： $s_{\hat{y}}^2 = 0.5679 \times 0.7307 + \dots + 0.2613 \times 0.8213 = 0.9823$ (已知 $s_{\hat{y}_z}^2 = \sum_{k=1}^p r_{ky} b_{zk}$)，得到残差方差 $s_e^2 = 1 - s_{\hat{y}}^2 = 0.0177$ 。随后对回归方程进行统计检验，计算 $F = \frac{U/p}{Q/(n-p-1)} = \frac{0.9823/3}{0.0177/(13-3-1)} = 166.4$ 。

在显著水平 $\alpha = 0.05$ 下， $F > F_\alpha$ ，说明该方程是显著的。

以上用的是多元线性回归方法。但是这是否说明三个因子对预报量都有显著影响呢？

对回归系数检验，利用 $F_k = \frac{b_k^2/c_{kk}}{Q/(n-p-1)}$ 发现 b_1 是显著的，而 b_2 和 b_4 是不显著的。

通过例子说明，尽管回归方程是显著的，并不能说明方程中所有因子都对预报量有显著影响。因此上述回归方程不是最优的。我们下面通过逐步回归方法来得到最优的回归方程。

4.3 逐步回归方法

小节引入

在气象预报中，对预报量的预报常常需要从可能影响预报 y 的诸多因素中挑选一批关系较好的作为预报因子，应用多元线性回归的方法建立回归方程来做预报。但如何才能保证在已选定的一批因子中得到最优的回归方程呢？逐步回归分析方法就是针对这一问题提出的一种常用方法。

4.3.1 预报因子(回归系数)的显著性检验

方差贡献 若在 p 个预报因子中去掉一个因子 k ，再建立它们对 y 的预报方程，则此时回归平方和、残差平方和分别记为 $U^{(p-1)}$, $Q^{(p-1)}$ ，定义单个预报因子的方差贡献：

$$V_k = U^{(p)} - U^{(p-1)} = Q^{(p-1)} - Q^{(p)} = \frac{b_k^2}{C_{kk}}, \quad k = 1, 2, \dots, p$$

其中 C_{kk} 是因子离差矩阵 $C = (X'X)^{-1}$ 的对角线上的元素。我们利用方差贡献判断因子的重要性。

有公式： $s_{\hat{y}}^2 = \frac{1}{n}U = \sum_{k=1}^p b_k s_{ky} = \sum_{k=1}^p \frac{b_k^2}{C_{kk}}$ $C_{kk} = [\sum_{i=1}^n (x_{ki} - \bar{x}_k)^2]^{-1}$

假设检验

在多元线性回归方程的建立中，尽管最后都作了方程的统计检验，但并不意味着在 p 个因子中，每个因子对预报量 y 的影响都是重要的。需要对每个因子进行考察，若某个因子对预报量 y 的作用不显著，那么在多元线性回归方程中它前面的系数就可能近似为0。

因此，检验某一因子是否显著等价于检验假设 $H_0: \beta_k = 0$ 。

统计量的确定

要对 β_k 作假设检验，自然就要寻找它的样本统计量 b_k 和与它有关的统计量的分布。因为最小二乘估计的 b_k 是随机变量 y_i 的线性函数，由于这些随机变量是遵从正态分布，则 b_k 也遵从正态分布。

统计量 $F_k = \frac{\frac{V_k}{q}}{\frac{Q/(n-p-1)}{(n-p-1)}} = \frac{b_k^2/C_{kk}}{Q/(n-p-1)}$ 符合自由度为 $(1, n-p-1)$ 的 F 分布。给定信度以后，查表求出标准值，

若 $F_k \geq F_\alpha$ ，说明该因子方差贡献显著，保留该因子，否则可以考虑从回归方程中剔除出去。

4.3.2 预报因子数目对回归方程的影响

具体影响 ① 一般而言，回归方程中包含的因子个数越多，回归平方和就越大，残差平方和越小。但是当因子增加到一定数目，残差平方和下降的幅度就很小了。一般回归方程的因子数目最多在 5-6 个左右为宜。
② 如果因子过多，则一方面对方程所起的贡献已不很大，另一方面会带来因子本身的各种随机因素，影响回归方程的稳定性，反而使预报效果下降。
③ 选择因子时要使因子之间的相关系数越小越好，而因子各自与预报量之间的相关系数越大越好。

关键问题 既要选择对预报量影响显著的因子，又要使回归方程的残差方差估计很小，这样才有利于气象预报。

4.3.3 逐步回归的三种方案

总体方案 逐步剔除方案、逐步引进方案、双重检验的逐步回归方案

4.3.3.1 逐步剔除方案

基本思想 从包含全部变量的回归方程中逐步剔除不显著的因子。

方案 假定有 p 个预报因子，首先用这 p 个因子建立回归方程，然后检查每个因子的方差贡献大小：

$V_k = \frac{b_k^2}{C_{kk}}, \quad k = 1, 2, \dots, p$ 从 V_k 中选出方差贡献最小者记为 V_{min} ，使用统计量 $F_k = \frac{V_{min}}{Q^{(l)}/n-l-1}$ 检验：

若显著，则其余因子也是显著的。若不显著，则剔除这一因子，对该因子对应的列进行消去后重复上面的步骤。其中 $Q^{(l)}$ 表示回归方程含 l 个因子时的残差平方和。

问题

- (1) 因子的方差贡献代表什么意义？
- (2) 为何不同时把几个不显著的因子从方程中剔除出去，而是要每次剔除一个？

问题一

回归平方和是所有因子对预报量的总贡献。所考虑的因子越多，回归平方和越大，若去掉一个因子，回归平方和只会减小，不会增加。减少的数值越大，说明该因子在回归中所起的作用越大，表明该因子越重要，所以，可用此衡量该因子的方差贡献大小。

$$V_k = U^{(l)} - U^{(l-1)}$$

V_k 就是去掉第 k 个因子后，回归平方和的减少量，这部分也叫做偏回归平方和，其衡量每个因子对回归方程所起作用的大小。

问题二

在剔除因子过程中，假如 x_1, x_2 方差贡献都比较小（甚至相等），我们也只能剔除其中的最小者，而不应该全部去掉。因为这两个因子之间可能存在密切相关关系，剔除 x_1 后，其对 y 的影响很大部分可以转加到 x_2 对 y 的影响上，所以回归平方和不会因此减小很多。但如果同时去掉两个因子，就会比较多的减少回归平方和，从而影响回归的精度。

4.3.3.2 逐步引进方案

基本思想

在一批待选的因子中，考查他们对预报量 y 的方差贡献，挑选所有因子中方差贡献最大者，经统计检验是显著后，进入回归方程。

方案

如从 x_1, x_2, \dots, x_p 等因子中考察哪个因子方差在一元回归方程中贡献最大，首先计算：

$$V_k^{(1)} = U^{(1)} - U^{(0)} = U^{(1)} \quad (k = 1, 2, \dots, p)$$

$U^{(0)}$ 为回归方程中无任何因子时的回归平方和，此时为 0。

假如在 p 个因子中， x_k 的方差贡献最大，记为 V_{max} ，则据回归系数的检验公式遵从 F 分布的统计量进行检验：

$$F = \frac{V_{max}}{\frac{Q^{(1)}}{n-1-1}}$$

若显著，则该因子引进。设到 l 步，方程已有 l 个因子。若考虑从 $p-l$ 个因子中引进哪个变量时，还是要考察他们各个因子引进后的方差贡献，仍选取最大者，记为 V_{max} ，使用统计量：

$$F = \frac{V_{max}}{\frac{Q^{(l+1)}}{n-(l+1)-1}}$$

作检验，其中 Q^{l+1} 表示在将要引入回归方程的 $l+1$ 个因子时，回归方程的残差平方和。如此在方程中逐个地引入因子。

注意

这样得到的方程并不能保证其中所有因子都是显著的。因为各因子之间可能存在相关关系，引入新变量后，原有的变量就不一定仍然显著。所以，逐步引入方案不一定保证最后的回归方程是最优的。

4.3.3.3 双重检验的逐步回归方案

基本思想

将因子一个个引入，引入因子的条件是该因子的方差贡献显著；同时，每引入一个新因子，要对已引入的老因子逐个检验，将方差贡献变为不显著的因子剔除。

因此双重检验的逐步回归能使最后组成的方程只含有重要的变量，所建立的回归方程也称为最优回归方程。这一方法在目前气象统计预报中所常用。

方法

利用求解线性方程组求解求逆并行(紧凑)方案，使得计算因子方差贡献和求解回归系数同时进行。

优点

计算简便，由于每步都作检验，保证了最后所得方程中所有因子都是显著的。

第一步

准备工作：首先从标准化变量出发，利用标准回归方程组，建立相关系数增广矩阵，如下：

$$R^{(0)} = \left\{ \begin{array}{cccc} r_{11} & r_{12} & \cdots & r_{1p} & r_{1y} \\ r_{21} & r_{22} & \cdots & r_{2p} & r_{2y} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ r_{p1} & r_{p2} & \cdots & r_{pp} & r_{py} \\ r_{y1} & r_{y2} & \cdots & r_{yp} & r_{yy} \end{array} \right\}$$

第二步

引进因子：从 p 个待选的标准化因子 $x_{z1}, x_{z2}, x_{z3}, \dots, x_{zp}$ 中，考虑引进第一个因子时，建立引进因子的回归方程：

$$\hat{y}_{zk} = b_{zk} x_{zk} \quad (k = 1, 2, \dots, p)$$

引进方差贡献最大的那个因子。

$$V_k^{(1)} = U^{(1)} - U^{(0)} = U^{(1)} = b_{zk}^{(1)} r_{ky}^{(0)} = r_{ky}^{(1)} r_{ky}^{(0)} = \frac{[r_{ky}^{(0)}]^2}{r_{kk}^{(0)}} \quad (k = 1, 2, \dots, p)$$

括号表示第几步, 注意为计算方便, 式中回归(误差)平方和符号均用回归(误差)方差代替。假如在 p 个因子中, x_{zk} 的方差贡献最大, 记为 V_{max} , 据回归系数遵从 **F分布的统计量** 进行检验:

$$F = \frac{V_{max}}{\frac{Q^{(1)}}{n-1-1}} \quad Q^{(0)} = s_{yy} = 1 = r_{yy}^{(0)} \quad Q^{(1)} = Q^{(0)} - V_k^{(1)} = r_{yy}^{(0)} - \frac{[r_{ky}^{(0)}]^2}{r_{kk}^{(0)}} = r_{yy}^{(1)}$$

若显著, 则将第 k 个因子引进方程。这相当于对 $R^{(0)}$ 阵中第 k 列进行消去, 变成 $R^{(1)}$ 。

假定在前 l 步中已引入 l 个因子, 考虑 $p-l$ 个未引入的因子中的方差贡献时, 计算第 k 个因子方差贡献的公式:

$$V_k^{(l+1)} = \frac{[r_{ky}^{(l)}]^2}{r_{kk}^{(l)}} \quad V_k^{(1)} = \frac{[r_{ky}^{(0)}]^2}{r_{kk}^{(0)}}$$

计算中可利用前 l 步消去求逆的结果, 即用在 $R^{(0)}$ 作 l 次消去求逆变成 $R^{(l)}$ 矩阵后阵中的元素。这样可以简化过程的计算量。

其中 $V_{max} = V_k^{(l+1)}$, 如果发现第 k 个因子方差贡献最大, 则用它进一步作下面的显著性检验, 这时利用下面统计量作检验。

$$F = \frac{\frac{V_k^{(l+1)}}{Q^{(l+1)}}}{\frac{n-(l+1)-1}{n-(l+1)-1}} \quad \begin{aligned} Q^{(0)} &= s_{yy} = 1 = r_{yy}^{(0)} \\ Q^{(1)} &= Q^{(0)} - V_k^{(1)} = r_{yy}^{(0)} - [r_{ky}^{(0)}]^2 / r_{kk}^{(0)} = r_{yy}^{(1)} \\ Q^{(l)} &= r_y^{(l)} \\ Q^{(l+1)} &= r_{yy}^{(l)} - V_k^{(l+1)} \end{aligned}$$

在显著性水平 α 下, 若 $F > F_\alpha$, 则认为该因子方差贡献显著, 引入该因子。

第三步

剔除因子: 当因子引入后, 原来已引入的因子方差贡献会发生变化, 可能变为不显著, 因此要进行剔除, 剔除的标准是进行统计检验。可以证明, 在逐步回归中, **仅在第三个因子引入后才考虑剔除**。设已引进了 l 个因子, 考虑其中第 k 个因子的方差贡献, 使用如下公式:

$$V_k^{(l)} = \frac{[r_{ky}^{(l-1)}]^2}{r_{kk}^{(l-1)}} = \frac{[r_{ky}^{(l)} r_{kk}^{(l-1)}]^2}{r_{kk}^{(l-1)}} = \frac{[r_{ky}^{(l)}]^2}{r_{kk}^{(l)}}$$

找出其中最小者, 进行统计检验:

$$F = \frac{V_k^{(l)}}{r_{yy}^{(l)} / n - l - 1}$$

若该因子不显著, 则剔除。再对该因子所对应的列进行消去, 就当该因子从未进入过方程一样。自此, 每一步首先考虑有无因子需要剔除, 若有就进行剔除, 直到没有可剔除的因子时再考虑引入新因子, 如此进行下去, 直到既无因子剔除又无因子可引入为止。

第四步

计算结果: 设最后引入了 l 个因子进入回归方程, $R^{(0)}$ 变到 $R^{(l)}$, 则回归方程为:

$$\hat{y}_z = b_{z1}x_{z1} + b_{z2}x_{z2} + \dots + b_{zl}x_{zl}$$

其中: 标准化数据回归系数为: $b_{zk} = r_{ky}^{(l)}$

原始数据回归系数为: $b_k = \frac{s_y}{s_k} b_{zk} = \frac{s_y}{s_k} r_{ky}^{(l)}$ $b_0 = \bar{y} - b_1 \bar{x}_1 - b_2 \bar{x}_2 - \dots - b_k \bar{x}_k$

回归方程的残差平方和为: $Q = S_{yy} Q^{(l)} = S_{yy} r_{yy}^{(l)}$

回归平方和为: $U = S_{yy} - Q = S_{yy} (1 - r_{yy}^{(l)})$

复相关系数为: $R = \sqrt{\frac{U}{S_{yy}}} = \sqrt{1 - r_{yy}^{(l)}}$ 判断方程是否显著, 使用 t 检验。

回归方程的剩余标准差无偏估计量为: $\hat{\sigma} = \sqrt{\frac{S_{yy} Q^{(l)}}{n-l-1}} = \sqrt{\frac{S_{yy} r_{yy}^{(l)}}{n-l-1}}$ 可进行预报值的置信区间估计

引入公式 $V_k^{(l+1)} = \frac{[r_{ky}^{(l)}]^2}{r_{kk}^{(l)}}$ $F = \frac{V_k^{(l+1)}}{\frac{r_{yy}^{(l)} - V_k^{(l+1)}}{n-(l+1)-1}}$ 引进 3 个后考虑剔除

剔除公式 $V_k^{(l)} = \frac{[r_{ky}^{(l)}]^2}{r_{kk}^{(l)}}$ $F = \frac{V_k^{(l)}}{\frac{r_{yy}^{(l)}}{n-l-1}}$ 每一步中剔除结束后再引入

矩阵变换 这种变换通常被称为旋转变换：

$$a_{ij}^{(l+1)} = \begin{cases} \frac{1}{a_{kk}^{(l)}} (i = k, j = k) & ① \text{ 枢轴元素} \\ \frac{a_{kj}^{(l)}}{a_{kk}^{(l)}} (i = k, j \neq k) & ② \text{ 对应行} \\ -\frac{a_{ik}^{(l)}}{a_{kk}^{(l)}} (i \neq k, j = k) & ③ \text{ 对应列} \\ a_{ij}^{(l)} - \frac{a_{kj}^{(l)} a_{ik}^{(l)}}{a_{kk}^{(l)}} (i \neq k, j \neq k) & ④ \text{ 其余项} \end{cases}$$

- 注意 ① 上一步刚引入的变量下一步不可能剔除
 ② 上一步刚剔除的变量下一步不可能引入
 ③ 连续引入三个变量后考虑剔除

4.3.4 逐步回归的一些注意点与实例

- 注意点 ① 用逐步回归方法选出 p 个重要因子，在理论上和实践上都不能证明它们都是最优的。是经验的。
 ② 用逐步回归方法选取重要因子时，被选中的因子数目 p 的多少是值得注意的。通常 F_α 一般选取 4，作为否定域的临界值。
 ③ 逐步回归模型是正态线性回归模型。
 ④ 回归方程的稳定性：是否残差方差小，而且还要注意所得到的规律性在未来时间的样本内是否还存在。统计预报最基本的假设。
 ⑤ 逐步回归可以与一般回归混合使用。
- 优点 ① 和逐步剔除法相比，计算量较小。
 ② 逐步引入法虽然计算量小些，但是不一定保证最后的方程是最优的。
 ③ 逐步回归方法最后能得到一个较合理的最优回归方程。
- 缺点 ① 该方法最终只提供一个最优回归方程，而无其它选择的余地。
 ② 其次，需要计算机解决较大阶数的矩阵，对于手算有较大的工作量。
- 应用 应用广泛，工农业生产和科学研究所中的许多问题都可以用这种方法得到解决。如今，在实验数据的一般处理，经验公式的求得，因素分析，产品质量的控制，某些新标准的制定，气象及地震预报以及许多场合中，都会用到这种分析方法。
- 现况 目前，由于计算机的普及，逐步回归分析方法已经十分普遍。许多现成的计算软件可供使用。

实例分析

题目：设对某一预报量 y ，选择 4 个因子作预报，样本容量 $n = 13$ ，它们的资料见表 1。

i	1	2	3	4	5	6	7	8	9	10	11	12	13
x_1	7	1	11	11	7	11	3	1	2	21	1	11	10
x_2	26	29	56	31	52	55	71	31	54	47	40	66	68
x_3	6	15	8	8	6	9	17	22	18	4	23	9	8
x_4	60	52	20	47	33	22	6	44	22	26	34	12	12
y	78.5	74.3	104.3	87.6	95.9	109.2	102.7	72.5	93.1	115.9	83.8	113.3	109.4

对上面的资料作逐步回归，具体步骤如下：

准备阶段：构造相关系数的增广矩阵（5个变量） 这一步不可能存在大于一的值

$$R^{(0)} = \begin{bmatrix} 1 & 0.2286 & -0.8241 & -0.2455 & 0.7307 \\ 0.2286 & 1 & -0.1392 & -0.9730 & 0.8163 \\ -0.8241 & -0.1392 & 1 & 0.0295 & -0.5347 \\ -0.2455 & -0.9730 & 0.0295 & 1 & -0.8213 \\ 0.7307 & 0.8163 & -0.5347 & -0.8213 & 1 \end{bmatrix}$$

下面进行逐步回归计算：

第一步：计算各因子的方差贡献

$$V_1^{(1)} = \frac{[r_{1y}^{(0)}]^2}{r_{11}^{(0)}} = \frac{(0.7307)^2}{1} = 0.5339 \quad V_2^{(1)} = 0.6663 \quad V_3^{(1)} = 0.2859 \quad V_4^{(1)} = 0.6745 = V_{\max}$$

$$F = \frac{V_{\max}}{\frac{r_{yy}^{(0)} - V_{\max}}{13 - (1+0) - 1}} = \frac{0.6745}{\frac{1 - 0.6745}{13 - 2}} = 22.80 > F_a \quad \text{消去第四列, 得:}$$

$$R^{(1)} = \begin{bmatrix} 0.9397 & -0.0103 & -0.8169 & 0.2455 & 0.5291 \\ -0.0103 & 0.0533 & -0.1105 & 0.9730 & 0.0172 \\ -0.8169 & -0.1105 & 0.9991 & -0.0295 & -0.5105 \\ -0.2455 & -0.9730 & 0.0295 & 1 & -0.8213 \\ 0.5291 & 0.0172 & -0.5105 & 0.8213 & 0.3255 \end{bmatrix}$$

第二步：计算余下各因子的方差贡献：

$$V_1^{(2)} = \frac{[r_{1y}^{(1)}]^2}{r_{11}^{(1)}} = \frac{(0.5291)^2}{0.9397} = 0.2979 = V_{\max} \quad V_2^{(2)} = 0.0055 \quad V_3^{(2)} = 0.2609$$

$$\text{进行检验: } F = \frac{0.2979}{\frac{0.3255 - 0.2979}{13 - 2 - 1}} = 107.93 > F_a, \text{ 消去第一列得:}$$

$$R^{(2)} = \begin{bmatrix} 1.0642 & -0.0110 & -0.8693 & 0.2613 & 0.5631 \\ 0.0110 & 0.0532 & -0.1195 & 0.9757 & 0.0230 \\ 0.8693 & -0.1195 & 0.2890 & 0.1893 & -0.0505 \\ 0.2613 & -0.9757 & -0.1893 & 1.0642 & -0.6831 \\ -0.5631 & 0.0230 & -0.0505 & 0.6831 & 0.0275 \end{bmatrix}$$

第三步：计算余下各因子的方差贡献：

$$V_2^{(3)} = \frac{[r_{2y}^{(2)}]^2}{r_{22}^{(2)}} = \frac{(0.0230)^2}{0.0532} = 0.0099 = V_{\max} \quad V_3^{(3)} = 0.0088$$

$$\text{进行检验: } F = \frac{0.0099}{\frac{0.0275 - 0.0099}{13 - 3 - 1}} = 5.034 > F_a, \text{ 消去第二列得:}$$

$$R^{(3)} = \begin{bmatrix} 1.0665 & 0.2068 & -0.8940 & 0.4630 & 0.5679 \\ 0.2068 & 18.7970 & -2.2462 & 18.3402 & 0.4323 \\ 0.8940 & 2.2462 & 0.0206 & 2.3756 & 0.0012 \\ 0.4631 & 18.3402 & 2.3756 & 18.9577 & -0.2613 \\ -0.5679 & -0.4323 & 0.0012 & 0.2613 & 0.0177 \end{bmatrix}$$

第四步：计算已引入方程中的因子的方差贡献：

$$V_1^{(3)} = \frac{[r_{1y}^{(3)}]^2}{r_{11}^{(3)}} = \frac{(0.5679)^2}{1.0665} = 0.3024 \quad V_4^{(3)} = 0.0037 = V_{\min}$$

$$\text{作剔除的检验: } F = \frac{V_k^{(l)}}{\frac{r_{yy}^{(l)}}{n-l-1}} = \frac{0.0037}{\frac{0.0177}{13-3-1}} = 1.893 < F_a \text{ 故剔除 } x_{z4}, \text{ 消去第四列。}$$

得到的矩阵相当于仅消去过第1, 2列的矩阵:

$$R^{(2)} = \begin{bmatrix} 1.0552 & -0.2411 & -0.8360 & -0.0245 & 0.5743 \\ -0.2411 & 1.0547 & 0.0522 & -0.9684 & 0.6854 \\ 0.8360 & -0.0522 & 0.3183 & -0.1254 & 0.0340 \\ 0.0245 & 0.9684 & -0.1252 & 0.0528 & -0.0138 \\ -0.5743 & -0.6854 & 0.0340 & -0.0138 & 0.0213 \end{bmatrix}$$

第五步：计算余下因子 x_{z3} 的方差贡献：

$$V_3^{(3)} = \frac{[r_{3y}^{(2)}]^2}{r_{33}^{(2)}} = \frac{(0.0340)^2}{0.3183} = 0.0036$$

进行F检验，计算得： $F = \frac{0.0036}{\frac{0.0213-0.0036}{13-3-1}} = 1.83 < F_a$ ，认为 x_{z3} 不能引进，又无剔除，逐步回归到此结束。

第六步：计算最后结果：得到标准化变量的回归方程，如下 $\hat{y}_z = 0.5743x_{z1} + 0.6854x_{z2}$ 。

利用资料计算得到原始数据的回归方程为：

$$y = 52.58 + 1.468x_1 + 0.662x_2$$

复相关系数： $R = \sqrt{\frac{U}{S_{yy}}} = \sqrt{1 - r_{yy}^{(l)}} = \sqrt{1 - 0.0213} = 0.989$ ，剩余标准差： $\hat{\sigma} = \sqrt{\frac{S_{yy}r_{yy}^{(l)}}{n-l-1}} = 2.39$

消元的具体规则

基于上述案例，我们讨论：

$$R^{(0)} = \begin{bmatrix} 1 & 0.2286 & -0.8241 & -0.2455 & 0.7307 \\ 0.2286 & 1 & -0.1392 & -0.9730 & 0.8163 \\ -0.8241 & -0.1392 & 1 & 0.0295 & -0.5347 \\ -0.2455 & -0.9730 & 0.0295 & 1 & -0.8213 \\ 0.7307 & 0.8163 & -0.5347 & -0.8213 & 1 \end{bmatrix} \xrightarrow{\text{消去第四列}} R^{(1)} = \begin{bmatrix} 0.9397 & -0.0103 & -0.8169 & 0.2455 & 0.5291 \\ -0.0103 & 0.0533 & -0.1105 & 0.9730 & 0.0172 \\ -0.8169 & -0.1105 & 0.9991 & -0.0295 & -0.5105 \\ -0.2455 & -0.9730 & 0.0295 & 1 & -0.8213 \\ 0.5291 & 0.0172 & -0.5105 & 0.8213 & 0.3255 \end{bmatrix}$$

因为选择了 x_4 ，所以 $k = 4$ ，此时分母总是枢轴元素 $a_{kk}^{(l)} = a_{44}^{(0)} = 1$ 。

① 计算枢轴点：利用公式 $1/a_{kk}^{(l)}$ ($i = k, j = k$)，故矩阵中(4,4)位置为 1。

② 计算第四行：利用公式 $\frac{a_{kj}^{(l)}}{a_{kk}^{(l)}} (i = k, j \neq k)$ ，即 **新第 4 行 = 旧第 4 行 / 枢轴元素**，由于 $a_{kk}^{(l)} = 1$ ，数值不变。

③ 计算第四列：利用公式 $-\frac{a_{ik}^{(l)}}{a_{kk}^{(l)}} (i \neq k, j = k)$ ，即 **新第 4 列 = -旧第 4 列 / 枢轴元素**，这一步需要变号。

④ 计算其他所有元素：较为复杂 $a_{ij}^{(l)} - \frac{a_{kj}^{(l)}a_{ik}^{(l)}}{a_{kk}^{(l)}} (i \neq k, j \neq k)$ ，有：

$$\text{新元素} = \text{旧元素} - \frac{(\text{该元素所在行的第 } k \text{ 列元素} \times \text{该元素所在列的第 } k \text{ 行元素})}{\text{枢轴元素}}$$

例如，对于(1,2)位置的元素，有：

$$0.2286 - \frac{-0.2455 \times -0.9730}{1} = 0.2286 - 0.23887 = -0.0103$$

依次计算可得。