

第四章 回归分析

4.1 一元线性回归分析

回归分析

回归分析是用来寻找若干变量之间统计联系（关系）的一种方法。它是一种统计模型，分为线性回归和非线性回归，线性回归在气象中最为常用（解释性好，物理机理较为清晰）。利用回归分析得到的统计关系对某一变量作出未来时刻的估计，称为预报值(量)。前期（也可以是同期因子）已发生的多个与之有关的气象要素称为预报因子。

案例分析

为了预报某地某月平均气温或降水量情况（预报量），选择预报前期已发生的多个有关的气象要素（预报因子），利用回归分析方法分析多个预报因子和预报变量之间的相互关系，建立统计关系的方程式，最后利用其对未来时刻的气温或降水量作出预报估计。

一元回归

一元回归分析处理的是两个变量之间的关系，即一个预报量和一个预报因子之间的关系。

4.1.1 回归模型

基本原理

对抽取容量为 n 的预报量 y 与预报因子 x 的一组样本（必须保证样本个数一致），若认为 y 与 x 是一元线性统计关系，则线性回归方程为： $y_i = b_0 + bx_i + \varepsilon_i$, $i = 1, 2, \dots, n$ (ε_i 为残差项，我们希望它越小越好)，那么预报量的估计量 \hat{y} 与 x 有如下关系：

$$\hat{y}_i = b_0 + bx_i \quad i = 1, 2, \dots, n$$

或写为一般的回归方程： $\hat{y} = b_0 + bx$ ，其中 b_0 为截距， b 为斜率。

最小二乘法

对所有的 x_i ，若 \hat{y}_i 与 y_i 的偏差最小，就认为所确定的直线能最好地代表所有实测点的散布规律。

为了消除偏差符号的影响，可以用偏差的平方来反映偏差的绝对值偏离情况。

全部观测值与回归直线的离差平方和记为：

$$Q(b_0, b) = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

它刻画了全部观测值与回归直线的偏离程度。显然 Q 值越小越好， Q 是待定系数 b_0 和 b 的函数。

标准方程组

根据极值原理，要求： $\frac{\partial Q}{\partial b_0} = 0, \frac{\partial Q}{\partial b} = 0$ 。整理得到求回归系数 b_0 、 b 的方程组：

$$\begin{cases} nb_0 + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \\ b_0 \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i \end{cases}$$

称为求回归系数的标准方程组。

具体求解

$$\textcircled{1} \quad \frac{\partial Q}{\partial b_0} = \frac{\partial}{\partial b_0} \left(\sum_{i=1}^n (y_i - b_0 - bx_i)^2 \right) = \sum_{i=1}^n -2(y_i - b_0 - bx_i) = 0 \Rightarrow \sum_{i=1}^n (-y_i - b_0 - bx_i) = 0 \Rightarrow$$

$$nb_0 + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i \quad \text{其中} \quad \frac{\partial (y_i - b_0 - bx_i)^2}{\partial b_0} = 2(y_i - b_0 - bx_i) \cdot (-1)。$$

$$\textcircled{2} \quad \frac{\partial Q}{\partial b} = \frac{\partial}{\partial b} \left(\sum_{i=1}^n (y_i - b_0 - bx_i)^2 \right) = -2 \sum_{i=1}^n x_i (y_i - b_0 - bx_i) = 0 \Rightarrow b_0 \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

回归系数	$b_0 = \bar{y} - b\bar{x}$	$b = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{s_{xy}}{s_x^2}$
距平形式	将 $b_0 = \bar{y} - b\bar{x}$ 代入回归方程 $\hat{y}_i = b_0 + bx_i$, 得到 $\hat{y}_i - \bar{y} = b(x_i - \bar{x})$ 或 $\hat{y}_{di} = bx_{di}$	
标准化形式	发现有关系: $b = \frac{s_{xy}}{s_x^2} = \frac{s_{xy}}{s_x s_y} \cdot \frac{s_y}{s_x} = r_{xy} \cdot \frac{s_y}{s_x}$, 由此 $\hat{y}_{zi} = r_{xy} x_{zi}$ (这里的 x, y 都是标准化后的变量)	

相关系数 回归系数 b 与相关系数之间的关系: $b = \frac{s_{xy}}{s_x^2} = r_{xy} \cdot \frac{s_y}{s_x}$ 相关系数 r 与回归系数 b 同号

当 $b < 0$, 回归直线斜率为负, 预报量 y 随预报因子 x 增加而减少, 反映预报量与因子是负相关。

当 $b > 0$, 回归直线斜率为正, 预报量 y 随预报因子 x 增加而增加, 反映预报量与因子是正相关。

4.1.2 回归问题的方差分析

意义 评价回归方程的优劣

预报量方差 预报量方差可以表示成回归估计值的方差(回归方差)和误差(残差)方差之和:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

即 $s_y^2 = s_{\hat{y}}^2 + s_e^2$ 。

评估分析 方差分析表明, 预报量 y 的变化可以看成由前期因子 x 的变化所引起的, 同时加上随机因素 e 的影响, 这种前期因子 x 的变化影响可以用回归方差的大小来衡量。如果回归方差大/残差方差小, 表明用线性关系解释 y 与 x 的关系比较符合实际情况, 回归模型比较好。

离差平方和 $\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 两边同时乘以 n 变成各变量离差平方和的关系。

总离差平方和: $s_{yy}^2 = U + Q = \sum_{i=1}^n (y_i - \bar{y})^2$ 反映因变量 y 的 n 个观测值与其均值的总离差

回归平方和: $U = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ 反映回归值的分散程度

残差平方和: $Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ 反映观测值偏离回归直线的程度

4.1.3 相关系数与线性回归

判决系数 因为回归方差不可能大于预报量的方差, 可以用它们的比值来衡量方程的拟合效果。即:

$$\frac{s_{\hat{y}}^2}{s_y^2} = \frac{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2} = \frac{U}{s_{yy}^2} = r_{xy}^2$$

上式表明预报因子 x 对预报量 y 的方差的线性关系程度, 这一比值又称为回归方程判决系数/解释方差。

判决系数是衡量两个变量线性关系密切程度的量, 等于两变量相关系数的平方。

如果是多元线性回归, 合理猜想, 是复相关系数的平方。

- | | | |
|------|--|-----------------|
| 物理含义 | ① 回归平方和占总离差平方和的比例 | 反映回归直线的拟合程度 |
| | ③ 取值范围在 $[0, 1]$ | ④ 判决系数等于相关系数的平方 |
| | ⑤ $r^2 \rightarrow 1$ 说明回归方程拟合的越好, $r^2 \rightarrow 0$ 说明回归方程拟合的越差 | |

4.1.4 回归方程的显著性检验

中心思想 显著性检验的主要思想是检验预报因子与预报量是否有线性关系。

统计量 可以证明在原假设总体回归系数为 0 的条件下, 统计量:

$$F = \frac{U/1}{Q/(n-2)}$$

遵从 分子自由度为 1, 分母自由度为 $(n-2)$ 的 F 分布。

显著性检验 查 F 的分布表, 在 $\alpha = 0.05$ 下, 若 $F > F_{\alpha}$ 则认为回归方程是显著的。反之, 则不显著。

相关系数 统计量 F 也可以写为: $F = \frac{U/1}{Q/(n-2)} = \frac{s_{\hat{y}}^2/1}{s_e^2/(n-2)} = \frac{r^2}{(1-r^2)/(n-2)}$, 与 $t = \frac{r}{\sqrt{1-r^2}} \sqrt{n-2}$ 比较, 发现二者等价。

注意 F 的相关系数表达式开方就是相关系数 t 检验的表达式, 故一元回归方程的检验与相关系数的检验一致。

4.1.5 回归系数的显著性检验

说明 气象中使用最多的是回归方程的距平形式，所以对回归方程的显著性检验可以只对因子的回归系数进行检验。

统计量 在原假设 $H_0: \beta = 0$ 的条件下，统计量 $t = \frac{b - \beta}{\sqrt{\frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}} = \frac{b/\sqrt{c}}{\sqrt{Q/(n-2)}}$ 遵从自由度为 $n - 2$ 的 t 分布。

$$\text{其中: } \hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{Q}{n-2} \quad c = [\sum_{i=1}^n (x_i - \bar{x})^2]^{-1}$$

或者根据 F 分布与 t 分布的关系，统计量 $F = \frac{U/1}{Q/(n-2)} = \frac{b^2/c}{Q/(n-2)}$ 遵从分子自由度为 1，分母自由度为 $n - 2$ 的 F 分布。其中 $U = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^n (b_0 + bx_i - b_0 - b\bar{x})^2 = b^2 \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{b^2}{c}$

4.1.6 预报值的置信区间

置信区间 因为 $e_i = y_i - E(y_i)$ 可以看成遵从 $N(0, \sigma^2)$ 的正态分布，所以其 95% 的置信区间为 $E(y_i) \pm 1.96\sigma$

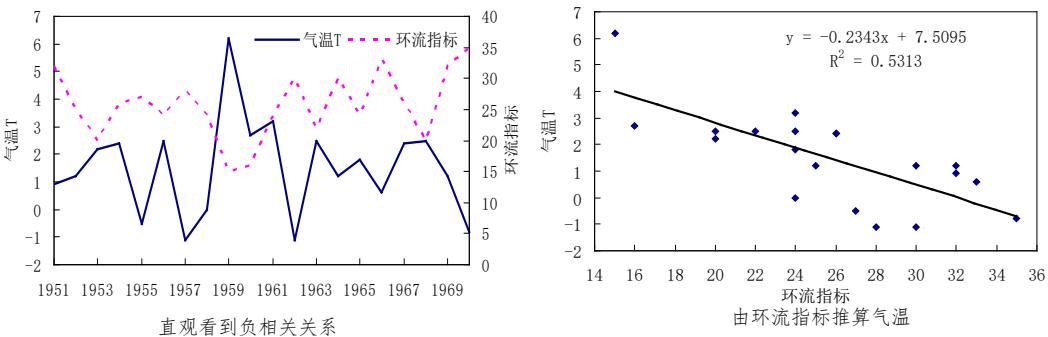
$E(y_i)$ 可用 $b_0 + bx_i = \hat{y}_i$ 估计， σ 可用无偏估计量 $\hat{\sigma} = \sqrt{\frac{Q}{n-2}}$ 估计， $\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

预报值的 95% 置信区间可近似估计为 $[\hat{y}_i - 1.96\hat{\sigma}, \hat{y}_i + 1.96\hat{\sigma}]$ 。

每一个点的置信区间都不一样，置信区间上下界是一个曲线。

4.1.7 一元线性回归分析预测步骤

分析数据



第一步 计算回归系数，确定方程。对上述资料，容易算得 $n = 20$, $\sum_{i=1}^{\infty} x_i = 513$, $\sum_{i=1}^{\infty} y_i = 30.0$,

$$\sum_{i=1}^1 x_i^2 = 13721, \sum_{i=1}^2 x_i y_i = 637 \quad \text{根据 } b_0 = \bar{y} - b\bar{x}, b = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2} = \frac{S_{xy}}{S_x^2} \quad \text{可以解得:}$$

$$b_0 = 7.5, b = -0.23 \quad \text{最终得到回归方程: } \hat{y} = 7.5 - 0.23x$$

第二步 回归方程显著性检验。

$$\text{再次计算得到: } \sum_{i=1}^1 y_i^2 = 103.12 \quad \text{于是 } r_{xy} = \sqrt{\frac{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2}} = \sqrt{\frac{13721 - \frac{1}{20} \times (513)^2}{103.12 - \frac{1}{20} \times (30.0)^2} \times (-0.23)} = -0.727$$

$$\text{最终得到: } F = \frac{(-0.727)^2}{[1 - (-0.727)^2]/(20-2)} = 20.18 \quad \text{查询} F \text{ 分布表, 在} \alpha = 0.05, \text{ 分子自由度为 1, 分母自由度为}$$

18 时, $F_\alpha = 4.41$ 由于 $F > F_\alpha$ 认为回归方程是显著的。 (考试可以灵活应用 t 检验)

第三步 计算预报值的置信区间，作出预测。

将 $x = 24$ 代入回归方程，计算出预报值为 $y_{24} = 1.98^\circ\text{C}$ ，又有 $Q = s_{yy} - U = s_{yy} - s_{yy}r^2 = s_{yy}(1 - r^2)$

$$\text{算出: } \hat{\sigma} = \sqrt{\frac{1}{20-2} \times 58.12(1 - 0.727^2)} = 1.11, \quad \text{用 } E(y_i) \pm 1.96\sigma \text{ 得到置信区间。}$$

所以 1971 年北京 3 月下旬气温的 95% 置信区间为 $-0.2 \sim 4^\circ\text{C}$ 。